

떠먹이 1기·2기 감성 분석 보고서

데이터 구조 · 예시 · 감성 분석 방법론 · 결과 · 인사이트 | 클로드코드 논문챌린지 참가자 로그 분석

한 문장 요약

두 기수(1기 448건·2기 307건) 참가자 글을 3단계 감성 측정(간이사전→KNU 사전→LLM)으로 분석한 결과, ① 사전이 만든 ‘Day0 고점’은 어휘 착시였고 LLM으로 보면 감성은 미션 내내 꾸준히 높다(만족), ② 인간 개입이 기분을 낮춘다는 신호는 교란 통제 후 사라졌다, ③ 1기·2기는 감성·완주·AI 문체가 매우 유사하다.

755

참가자 제출글 (1기 448 + 2기 307)

3단계

감성 측정 (사전→KNU→LLM)

88%

LLM 라벨 긍정 (부정 1%)

≈0

교란 통제 후 개입 효과

1. 데이터는 어떻게 생겼나 (구조 · 예시)

“떠먹이(클로드코드 논문챌린지)”는 참가자가 5일 미션(Day0 자기소개 ~ Day5)을 하며 게시판에 글을 올리면 AI 튜터와 운영자(사람)가 댓글로 돕는 프로그램이다. 활동 로그가 가명화 CSV로 저장돼 있다.

2기 (온플랫폼 통합)

파일	내용	행
assignments_posts	참가자 제출글(감성 Y)	307
assignments_comments	AI·운영자·동료 댓글	396
users	참가자·완주 여부	75

댓글 유형: AI 242 · 운영자(사람) 127 · 동료 27 — 인간 개입이 플랫폼에서 분리 관찰됨.

1기 (전체 플랫폼 export)

파일	내용	행
assignments_posts	참가자 제출글(감성 Y)	448
ai_feedback_comments	AI 피드백 원문	471
users	참가자 104(완주 66)	107

댓글 유형: ai_operator 471 · 동료 81 — 인간 개입은 플랫폼 밖 카카오톡(별도 분석).

제출글 예시 (미션Day별 · 대표 형태)

Day	글 성격	대표 내용(요약)
Day0	자기소개	“박사과정/인공지능. AI 에이전트로 논문 워크플로우를 구축하고 싶습니다. 다같이 화이팅!”
Day1	설치·첫 미션 회고	“설치가 처음이라 오류가 났지만 클로드에 물어보며 해결했습니다. 연구 주제 탐색에 도움이 될 것 같아요.”
Day3~5	논문 파이프라인 회고	“참고문헌 정리·초안까지 해봤습니다. 토큰 리미트가 아쉬웠지만 큰 도움이 됐어요!”

※ 개인 식별 정보를 제거한 대표 형태. 실제 원문은 커밋·공개하지 않음.

전처리 핵심

두 기수 모두 day=999의 기계 생성 JSON 아티팩트({ "version":1,...}), 1기 71건·2기 45건)가 가짜 감성값으로 섞여 있어 전량 제외했다. 이것을 안 걸렀다면 특정일 감성이 왜곡된다.

2. 감성 분석 방법론 — 3단계로 강건성 확보

“글이 긍정이나 부정이나”를 재는 방법을 3단계로 올려가며 결론이 도구에 흔들리지 않는지 검증했다.

① 간이 사전(pilot) → ② KNU 한국어 감성사전 + 형태소분석 → ③ LLM 주석(최신 표준)

단계	방법	원리	한계
① 간이사전	긍/부정 단어 개수 세기	빠름·투명	문맥·부정어 무시
② KNU 사전	KNU 감성사전(14,854엔트리) + Okt 형태소분석 + 부정어 처리	정식 리소스, 부정어(안/못/없다) 반영	여전히 단어 기반 → 어휘 착시
③ LLM 주석	코드북(valence -2~+2·감정·대상)으로 LLM이 문장 의미를 읽어 라벨	문맥·반어·해결서사 이해	단일 주석자 → κ 검증 필요

왜 LLM인가 (근거)

Rathje 2024 *PNAS*, Gilardi 2023 *PNAS*, Ziems 2024 *Computational Linguistics* — 최신 연구는 감성/텍스트 라벨링에서 사전보다 LLM이 인간 코더에 더 근접함을 보고. 본 분석도 그 결과를 재현.

감성 사전이 단어에 매기는 점수 (예시)

긍정 단어	점수	부정 단어	점수
감사 · 좋다 · 도움	+2	어렵다 · 오류 · 막히다	-1
기대 · 화이팅 · 신기	+1	실패 · 좌절 · 못하다	-2

사전의 합정 = 어휘 착시

Day1 회고 “오류가 났지만 해결해서 뿌듯했다”는 실제로 긍정이지만, 사전은 ‘오류·어려웠다’ 단어 때문에 낮게 매긴다. 반대로 Day0 자기소개는 ‘화이팅·응원·기대’가 밀집돼 과대 평가된다. → 그래서 사전은 “Day0 고점 → Day1 급락”이라는 가짜 곡선을 만든다. LLM은 문장의 실제 의미(고생→해결→만족)를 읽어 이를 건너낸다.

혼재변수(교란) 통제 — “떡진 데이터” 걸러내기


“인간 개입이 기분을 낮춘다”가 진짜 인과인지 확인하려면 개입과 얹힌 다른 요인을 걸어야 한다.

방법	무엇을 통제
고정효과 (FE)	사람마다·미션Day마다 다른 기본 성향
성향점수매칭 (PSM)	‘개입받을 만한’ 비슷한 사람끼리 비교
분포시차 회귀 / 개입 전후 t-test	개입 후 시차를 두고 감정 변화 추적 (역인과 차단)

3. 결과


3-1. 핵심 발견 ① — 사전의 'Day0 고점'은 착시 (LLM으로 재측정)

그림 1 · 2기



2기: 간이사전은 Day0 고점→급락(주황)이지만 LLM(파랑)은 전 구간 높게 유지. Day 단위 두 측정 상관 -0.25(거의 반대).

그림 2 · 1기




1기: KNU 사전(주황) Day0→Day1 낙차 0.166이 LLM(파랑)에선 0.093으로 절반 축소, Day5 반등. 사전의 Day0 착시가 두 기수 모두에서 확인·완화됨.

측정 도구를 사전→LLM으로 바꾸니 “Day0 고점→하락” 패턴이 걸렸다. 실제 참가자 감성은 미션 내내 꾸준히 높다(만족). 1기 LLM 라벨 긍정 88% · 부정 1% — 부정 5건은 모두 토큰 리밋·설치 에러로 인한 좌절(AI 품질 문제가 아님).

3-2. 핵심 발견 ② — 인간 개입 효과는 교란 통제 후 사라진다 (2기)

그림 3 · 2기




인간 개입 효과: 통제가 강한 방법일수록 계수가 0으로 수렴하고 신뢰구간이 0을 지난다. 유일하게 견고한 신호는 ‘직전 감성의 음(-)의 계수 = 평균회귀’.

방법	인간 개입 효과	유의성
순진한 비교 (t-test)	-0.195	p=.004 유의
고정효과 (FE)	-0.069	p=.34 비유의
성향점수매칭 (PSM)	-0.002	p=.98 효과 없음

해석
겉보기엔 “인간 개입이 기분을 낮춘다” (-0.195)처럼 보이지만, 이는 운영자가 힘든 사람에게 먼저 개입한 선택편향 + 평균회귀의 착시. 교란을 통제하면 효과는 0. 이 결론은 간이사전·KNU·LLM 세 측정 모두에서 동일(매우 강건).

3-3. 인간 vs AI — 같은 Day에서 감성 차이 없음 (2기)


그림 4 · 2기



같은 미션Day에서 운영자(사람) 개입 제출과 AI 개입 제출의 감성은 사실상 동일. pilot·KNU·LLM 세 측정 모두 같은 결론.


3-4. 코호트 비교 — 1기와 2기는 매우 유사

그림 5



미션Day 감성 궤적이 거의 겹침. 전체 평균 1기 +0.243 · 2기 +0.254. Day0 고점→안정 패턴도 동일.

그림 6




AI 문체 인간유사성(HL): 1기 AI 0.04 ≈ 2기 AI 0.03 (사람 운영자만 0.94). ‘AI가 1기→2기에 기계적으로 변했다’는 초기 주장은 부분 데이터 착시였음을 정정.

지표	1기	2기
참가자 제출글	448	307
전체 평균 감성 (KNU)	+0.243	+0.254
전일 완주율	63%	—
AI 피드백 인간유사성(HL)	0.04	0.03

3-5. 보너스 — 1기 카카오톡: ‘마찰의 창구’

그림 7 · 1기 카톡



카톡 참가자 감성 저점이 미션 종료 직후(4/7~4/13)에 온다. 남은 사람들이 막판 문제·토론 이슈를 토로하던 시기.

채널이 감성을 결정한다

정제된 플랫폼 제출글은 부정 1%지만, 실시간 카톡 참가자 메시지는 부정 22%. 설치 오류·토큰 리밋 같은 진짜 마찰은 카톡에 드러난다. 제출글만 보면 만족도가 과대평가된다.

4. 인사이트 & 다음 단계

핵심 인사이트

1. 측정 방법이 결론을 바꾼다. “Day0 고점→하락”은 사전 (lexicon)이 만든 어휘 착시. LLM으로 보면 감성은 **미션 내내 높다 (만족)**. → 감성 측정은 LLM으로 해야 한다는 최신 방법론의 실증이자 본 연구의 핵심 기여.
2. 관찰 데이터로는 개입의 인과를 못 가른다. 인간 개입 효과는 교란(선택편향·평균회귀) 통제 후 0. 인간 vs AI 감성 차이도 없음. 세 측정 모두에서 강건.
3. 1기·2기는 놀랍도록 유사하다. 감성 궤적·완주율·AI 문체 모두 유사 → 프로그램의 핵심 경험이 안정적으로 재현됨.
4. 부정 감정의 원천은 AI가 아니라 마찰이다. 부정은 대부분 토큰 리밋·설치 에러. 카톡(부정 22%)이 제출글(1%)이 감춘 마찰을 드러낸다.

연구적 함의 — 왜 통제 실험이 필요한가

관찰 데이터에서는 개입 주체(인간/AI)·개입 시점·미션Day·감성 천장효과가 서로 얽혀 있어, 시차·혼재 통제를 다 해도 X_1 (인간 개입)· X_2 (AI 인간유사성)의 순효과를 가릴 수 없다. → 3·4기에서 인간/AI·인간유사성(HL)·피드백 유형을 무작위 배정하면 여기서 못 가른 인과를 규명 가능. 1기·2기의 유사성은 “자연 변이만으론 이 변수들이 거의 안 움직인다”는 근거다.

다음 단계

- 인간 gold 코딩 + κ /F1로 LLM 측정 신뢰도 확립 (사람 2명이 200~300개 독립 코딩).
- 1·2기 LLM 라벨 통합 → 삼중 측정(간이·KNU·LLM) 코호트 비교표.
- 대상 기반(ABSA)으로 ‘AI에 대한 감정’ vs ‘과제에 대한 감정’ 분리.
- 3·4기 통제 실험 설계에 본 측정 파이프라인 그대로 적용.

재현 스크립트: `analysis/full_pipeline.py` · `knu_reanalysis.py` · `llm_sentiment_labels.csv` · `cohort1_pipeline.py` · `cohort1_llm_sentiment.py` · `kakao_1gi.py`. 데이터는 가명화 집계·라벨(텍스트 없음)만 포함하며 참가자 원문·개인정보는 공개하지 않습니다.