

‘떠먹이’ 2기 데이터 분석 — 감성 분석으로 본 AI·인간 개입 효과

작성: 수정 · 대상 데이터: 클로드코드 논문챌린지 2기(관찰 데이터) · 분석: 감성분석 + 준실험 설계

한 장 요약

- ① 관찰 데이터에서 인간 개입 효과는 통제 후 비유의(여러 방법 수렴). ② 인간 vs AI 개입의 감성 차이도 없음(세 측정 모두 동일). ③ 단, AI·인간은 다른 종류의 피드백을 줌(AI=인지/교육, 인간=정서/관계). ④ AI 인간유사성(X_2)은 문체가 거의 안 변해 관찰로 추정 불가. ⑤ ★ 측정을 LLM으로 바꾸니 기존 사전 기반의 ‘Day0 고점→하락’이 착시로 드러남. → 결론: 2기 관찰분석은 방법론적 기여 + 3·4기 통제 실험 필요.

1. 연구 배경 & 질문

문제: 2기 데이터엔 인간(운영자) 개입(X_1) 과 AI의 인간유사성(X_2) 이 뒤섞여 있음. 학생들은 “섞여서 못 쓴다”고 우려. 교수님 방향: 실서비스(revealed) 데이터는 원래 섞여 있고, 사후에 통계로 분리하는 방법이 있음 → 관찰 데이터용 설계로 분석.

- Q1** 어떤 개입(인간/AI)이 사용자 감성·지속에 효과가 있나? **Q2** 인간 vs AI 개입은 어떻게 다른가? **Q3** AI를 ‘사람처럼’ 만들면(X_2) 효과가 있나?

2. 데이터 & 방법 (요약)

데이터

- 학생 70명, 미션 제출 307건(Day0~5), 이벤트 1,064
- 정제: 5/25 기계생성 JSON 45건 제외(활동 289→244)
- 단위: 사용자×미션Day (늦게 한 제출도 같은 Day로 취합, 53%가 미션기간 이후)

감성 측정 (삼중)

- ① 간이 사전(원본) → ② KNU 감성사전+형태소 → ③ LLM 주석(코드북)
- 분석: 미션Day·사용자 고정효과(FE), PSM, 이벤트스터디, 분포시차
- 보조: 피드백 내용분석, 인간유사성 분류기(HL)

3. 핵심 결과


3.1 개입 효과(Q1) — 통제하면 사라진다

방법	인간개입 효과	유의
순진한 전후 비교	-0.195	유의 .004
다중회귀 / 분포시차(FE)	+0.003 / +0.044	n.s.
고정효과 PanelOLS	-0.069	.34
성향점수매칭 ATT	-0.002	.98

지속(retention)·완주도 동일 — 계속율 94%(천장), AI 피드백 98%(거의 전원)라 효과 식별 불가. 유일한 경계 신호: AI 피드백 ‘개수’ +3.6%p ($p=.05$).

3.2 인간 vs AI(Q2) — 같은 미션Day에서 감성 차이 없음


그림 1 · 같은 미션Day에서 운영자 vs AI 피드백 감성 (± SE)



Day1~2(둘 다 표본 충분)에서 두 선이 거의 겹침 → 인간·AI 감성 차이 없음. Day0가 높은 건 운영자만 있는 Day0(신기함) 효과. pilot·KNU·LLM 세 측정 모두 동일 결론.

3.3 피드백 ‘내용’은 뚜렷이 다르다 — 티칭 프레즌스 vs 사회적 프레즌스

그림 2 · AI vs 운영자 피드백 내용 프로파일




AI = 길고 ‘유도질문·가설·검증’ 많음(인지적/교육적). 운영자 = 짧고 이모티콘·격려 많음(정서적/관계적). 구별 단어: AI(가설·검증·회고·해보다) vs 운영자(감사·응원·반갑다·선생님).

→ AI와 사람이 자연스럽게 역할 분담(석인님 ‘티칭 프레즌스’ 연구의 실증 근거). 단, 내용 변동→결과 효과는 대체로 비유의(경계: 따뜻한 AI 피드백→다음 기분 살짝 ↑, $p=.06$).

3.4 AI 인간유사성(Q3) — 측정은 되나 변동이 없어 효과 추정 불가


그림 3 · AI 피드백의 인간유사성(HL) 분포



사람 vs AI 문체 분류기 AUC 0.99. AI 피드백 HL 평균 0.03(거의 사람 같지 않음) vs 운영자 0.94. AI 문체가 늘 기계적이라 X. 효과를 관찰로 추정할 반사실이 없음 → 3·4기서 조작 필요.

3.5 ★ 측정 방법론 발견 — LLM으로 재측정하니 결론이 바뀐다

그림 4 · 간이 사전 vs LLM 감성 (미션Day별)



간이 사전의 ‘Day0 고점(0.84)→하락’이 LLM으로 보면 사라짐(평평~상승). 두 측정의 Day별 상관 -0.25. Day0 고점은 자기소개의 긍정단어 밀집이 만든 착시였음(‘고생했지만 해결→만족’을 사전이 부정으로 오독).

의미
최신 표준(PNAS Rathje 2024; Computational Linguistics Ziems 2024)이 “사전 대신 LLM”을 권하는 이유의 실증 사례. 그 동안의 ‘Day0 평균회귀’ 서사는 상당 부분 측정 인공물이었고, LLM 측정에선 감성이 미션 내내 꾸준히 높다(만족). 단, 인간 vs AI 무차별 결론은 세 측정 모두에서 견고.

4. 종합 해석

- 관찰 데이터로는 인간/AI 순효과를 못 가른다 — 피드백이 near-universal(AI 98%) + 지속 천장(94%) + 개입이 미션Day와 완전히 얹힘.
- 측정은 LLM으로 — 사전 기반은 키워드 밀집에 속아 없는 패턴(Day0 고점)을 만든다.
- 내용은 다르다 — AI=인지적, 인간=정서적. 효과 차이는 관찰로 확인 불가.

5. 한계

- 단일 LLM 주석자 — 인간 코더 2명 gold(200~300개) + κ /F1 검증 필요(미실시).
- LLM 긍정 편향/범위 압축 — 라벨이 +1~+2에 몰림(회고글 특성 + 주석 편향 혼재).
- X_2 조작 불가·표본 307 — 관찰만으론 인과 한계.

6. 다음 단계 & 액션 아이템

논문 구조 제안
Study 1 (2기 관찰): “관찰 감성분석의 함정 + 측정(LLM) 강건성 + 인간/AI 무차별” 방법론적 기여 → 지금 논문화 가능. Study 2 (3·4기 실험): 인간 vs AI, 그리고 HL(인간유사성)·피드백 내용(유도질문형 vs 격려형)을 무작위 배정 → 인과 규명. HL 분류기를 조작 점검(manipulation check)으로 재사용.

즉시 할 일

- ☐ 인간 코더 2명 gold 코딩 (200~300) → LLM 감성 κ /F1 검증
- ☐ LLM·KNU·사전 삼중 비교표로 '측정 강건성 + Day0 착시' 정리
- ☐ 대상 기반(ABSA) 심화: 'AI에 대한 감정' vs '과제에 대한 감정' 분리
- ☐ 3·4기 실험 설계 확정(무작위 배정 조건·사전등록 outcome)

재현 코드: analysis/full_pipeline.py · knu_reanalysis.py · mission_day_analysis.py · feedback_effectiveness.py · feedback_content.py · hl_analysis.py · (LLM 라벨) llm_sentiment_labels.csv | 원본 참가자 데이터 미포함.