

떠먹이 2기 감성 분석 — 연구 & 방법론 정리

데이터 구조 · 전처리 · 분석 방법 · 결과를 처음 보는 사람도 이해하도록 정리했습니다. 플로우(Part 0 → 4) 순서 그대로.

딱 한 문장 요약

“인간(운영자) 개입이 사용자 기분을 나쁘게 한다”처럼 보였지만 알고 보니 착시였고, 제대로 분석하니 개입 효과는 없었다. 그 착시의 정체를 밝힌 것이 이 연구의 핵심이다.

1. 이 데이터는 어떻게 생겼나 (데이터 구조)

“떠먹이(클로드코드 논문챌린지 2기)”는 참가자가 5일 미션을 하며 게시판에 글을 올리면, AI 튜터와 운영자(사람)가 댓글로 도와주는 서비스다. 이 활동 로그가 가명화된 CSV 11개로 저장돼 있다.

파일	무엇	행 수
users.csv	참가자 명단·팀·완료 여부	75 (학생 70)
assignments_posts.csv	미션 제출글	384
assignments_comments.csv	제출글에 달린 댓글 (AI/운영자/참가자)	396
qna_posts / qna_comments	질문글 / 답변	89 / 162
notices.csv	운영자 공지	17
collective_posts.csv	집단지성 게시글	16
events_long.csv	위 글·댓글을 하나로 합친 통합 표	1,064
student_day_panel.csv	사용자 × 날짜 분석용 표	1,800

모든 글·댓글에는 세 종류의 정보가 이미 붙어 있다:

- 누가 썼나 (actor_type) — AI 튜터 / 운영자(인간) / 참가자. (통합표 기준: 참가자 502 · 운영자 315 · AI 247)
- 기분 점수 (sentiment) — 글의 감정을 -1(부정) ~ +1(긍정)로 매긴 값 + 긍/부정 단어수 + 글자수 + 주제 태그(설치·사용법·토큰한도·에러 등)
- 시간 — 작성 시각(타임스탬프)과 미션Day(0~5) 태그

분석의 “한 줄(ROW)”이 무엇인가 — 두 가지 방식

① 사용자 × 날짜(달력 기준) · ② 사용자 × 미션Day(Day0~5, 늦게 한 사람도 같은 Day끼리 묶음). 이 연구는 둘 다 써서 결론이 같은지 확인했다.

데이터 한 줄 예시 (가명화·개념 도식):

참가자=U0031 | 미션Day=2 | 날짜=2026-05-05 | 글="설치가 자꾸 실패해서 답답하네요..."
→ 기분점수 = -0.32 | 받은 AI댓글 = 1개 | 받은 운영자댓글 = 0개 | 주제 = 에러/디버깅

2. 데이터를 어떻게 손질했나 (전처리)

원본 로그를 그대로 분석하면 안 된다. 아래 6단계로 정리했다.

- 1 **운영자(관리자) 제외** — 분석 대상은 **학생 70명**. 운영진 5명은 뺐다.
- 2 **결과변수 Y 정하기** — 기분(Y)은 참가자가 쓴 글로만 측정. AI·운영자가 쓴 글은 기분이 아니라 ‘개입(X)’으로 분리한다. (감정의 ‘대상’을 나누는 것 = 대상 기반 분석)
- 3  **오염 데이터 제거** — 2026-05-25에 시스템이 자동 생성한 **JSON 45건** (`{"version":...}` 형태, day=999)이 참가자 글로 잘못 섞여 있었다. 사람이 쓴 글이 아니라 **가짜 기분점수(0.677)**를 만들어냈으므로 제외. **참가자 글 502 → 457건, 활동일 289 → 244건**.
- 4 **감성 재측정 (더 제대로 된 도구로)** — 원본에 딸린 *간이* 점수 대신 **KNU 한국어 감성사전(14,854 단어)** + 형태소분석(Okt) + **부정어 처리**(“안/못/않다” 뒤 단어는 부호 뒤집기)로 다시 매겼다. -1~+1로 정규화. 커버리지 97%, 간이 점수와 상관 $r=.56$ → 서로 다른 도구인데 방향 일치.
- 5 **분석용 표(패널) 만들기** — (a) **달력 패널**: 사용자×날짜에 개입 여부·직전 기분 등을 붙임. (b) **미션Day 패널**: 제출을 Day0~5로 묶어 **늦게 한 제출까지 포함**(총 307건). 제출별 피드백은 그 글이 받은 AI/운영자 댓글 수로 직접 측정.
- 6 **변수 만들기** — Y=기분, X_1 =운영자 개입(받은 댓글 유무), X_2 =AI 개입, 통제=시간 흐름·요일·글 길이·직전 기분·미션 Day·사용자.

원본 이벤트 1,064건 → (관리자·오염 제거, 참가자만) → 기분 데이터 Y 457건 · 활동 244 user-day · 미션 제출 307건

3. 분석 방법 6가지 — 처음 보는 사람도 이해하게

왜 방법이 여러 개인가
실험이 아닌 **관찰 데이터**는 한 가지 방법만으론 못 믿는다. 그래서 **서로 다른 방식으로 같은 결론이 나오는지(삼각검증)** 확인한다. 아래가 그 도구 상자다.

방법	쉽게 말하면	이 연구에서
ITS 단절적 시계열	개입 전후로 시간 추세가 끊기거나 바뀌었는지 비교	사용 미션 종료를 기준으로
분포시차 Distributed Lag	효과가 며칠 뒤까지 누적/지연되어 나타나는지	사용 당일+전일 개입
FE 고정효과	같은 사람/집단 안에서 안 변하는 특성을 통제 하고 전후 변화 비교	사용 사용자·날짜 고정효과
PSM 성향점수매칭	비슷한 애들끼리 짝지어 비교 (개입 받을 확률이 비슷한 날끼리)	사용
DID 이중차분	동일 추세 안에서 집단 간 전후 비교 (개입받은 집단 vs 안 받은 집단의 변화 차이)	대체 처치·대조 구분이 애매해 FE·이벤트스터디로 대신
SEM 구조방정식	여러 변수 간 관계 구조를 한 번에 (예: AI다움→기분→지속 경로)	다음 단계 매개효과 분석용

※ 이 밖에 개입 전후 t-test(전·후 평균 비교), 교차상관(며칠 뒤 관계), Granger(개입이 기분을 예측하나)도 보조로 사용.

Part 0. 문제 재정의 — “변인이 떡져 있다”는 포기 사유가 아니다

쉽게 말하면

데이터엔 ‘사람 개입’과 ‘AI다움’이 뒤섞여 있다. 학생들은 “섞여서 못 쓴다”고 걱정했지만, 교수님은 “실제 데이터는 원래 섞여 있고, 섞인 걸 통계로 떼어내는 방법이 있다”고 했다. 그 방법(위 3번의 도구들)을 쓰는 게 이 연구다.

기호	이름	이 데이터에서	측정?
Y	사용자 기분(감성)	참가자 글의 감성 점수	✓
X ₁	사람(운영자) 개입	운영자 댓글·공지	✓
X ₂	AI의 인간다움	AI 답변을 점수화	⚠ 원자료에 없음
통제	방해 요인	시간·요일·글길이·직전 기분	✓

Part 1. 감성 분석 — 글을 숫자로 바꾸기

쉽게 말하면

기분을 분석하려면 글을 숫자로 바꿔야 한다. 기분 좋은 글 = +1쪽, 나쁜 글 = -1쪽. (도구·검증은 전처리 4단계에서 설명)

믿을 만한가? 감성어 커버리지 97% · 도움요청(Q&A) 글이 과제 글보다 확실히 덜 긍정적(+0.09 ≪ +0.51) → **상식과 맞음 = 타당.**


Part 2. 시차 분석 — 개입 “뒤에”, 시간이 지나며 기분이 어떻게 변하나

쉽게 말하면

개입 효과는 바로 안 나타날 수 있어서 “며칠 뒤” 기분을 본다.

방법	이 데이터 결과
① 개입 전후 비교(t-test)	인간 -0.195 (겉보기 유의)
③ 단절적 시계열(ITS)	미션 종료 후 오히려 상승
④ 분포시차 회귀	+0.044 (효과 없음)
⑤ Granger	예측 못 함

그림 ① · 날짜별 사용자 기분 시계열



세로선 = 운영자 공지, 파란 점선 = 미션 종료. 종료 이후 남은 참가자 기분은 오히려 상승(생존자 효과).


Part 3. 변인 분리 — 섞인 두 원인을 통계로 떼어내기 (이 연구의 심장)

쉽게 말하면
‘사람 개입’과 ‘AI’를 한 계산에 같이 넣으면 각각의 순수한 효과가 나온다. 방해 요인(시간·직전 기분 등)을 통제하면 착시가 걷힌다.

방법을 강하게 할수록 (FE·PSM) 개입 효과가 0으로 수렴:

방법	인간 개입 효과	유의성
순진한 전후 비교	-0.195	유의 p=.004
다중회귀	+0.003	없음 .94
고정효과(FE)	-0.069	없음 .34
성향점수매칭(PSM)	-0.002	없음 .98

그림 ② · 개입 전후 기분 (평균회귀의 지문)



개입일(0)에 기분 최고 → 다음 날 급락. 인간(빨강)·AI(파랑)가 똑같이 떨어진다 → 개입 탓이 아니라 자연스러운 되돌아옴(평균회귀).


Part 3+. 미션Day 취합 — 늦게 한 참가자까지 포함 (가장 깨끗한 관점)

쉽게 말하면
사람마다 미션 한 날짜는 달라도 Day1~5 내용은 똑같다. 그래서 날짜 대신 미션Day 기준으로 모으면 늦게 한 사람(전체의 53%!)까지 살리고 같은 내용끼리 비교한다.

미션DAY	제출	기분	AI 도움율	운영자 도움율
Day0	61	0.843	0%	97%
Day1	54	0.421	98%	43%
Day2	50	0.389	98%	16%
Day3	49	0.475	96%	4%
Day5	46	0.535	94%	2%

착시의 정체
운영자(사람)는 Day0에 물뿔으로 도와주는데 Day0 기분이 원래 최고(신기함)다. 그 뒤 자연스럽게 내려간다 → “사람이 도와 주면 기분이 나빠진다”처럼 보이는 착시. 미션Day를 통제하면 개입 효과 사라짐(운영자 p=.56). 같은 Day에서 제때 vs 늦게 기분이 같음(Day1 p=.97) → 늦게 한 데이터 함께 써도 됨.

그림 ③ · 미션Day별 기분 & 피드백 노출



(왼쪽) 제때·늦게 기분 곡선이 거의 겹침. (오른쪽) 운영자 도움은 Day0에 물뿔, AI는 전 구간 일정.

Part 4. 워크플로우 & 결론

진행 현황: 데이터 정제 ☒ · 인간개입 표시(X_1) ☒ · AI 인간다움(X_2) ☐ ⚠️ 아직 · 감성 측정(Y) ☒ 간이→KNU · 분석 (FE·PSM·시차·미션Day) ☒ · 보고 ☒

결론

① 2기 데이터는 버리지 않는다. 지금 결과만으로도 “관찰 데이터를 대충 보면 틀린 결론이 나온다”는 방법론 논문이 된다. ② 인간 vs AI 중 뭐가 더 효과적인가는 2기만으론 못 가른다(개입이 Day0에 몰려서) → 3·4기 통제 실험(Study 2). ③ 구조: Study 1(2기 관찰) + Study 2(3·4기 실험) 다중연구 논문.

다음 할 일

- ☐ 감성 재측정 — KcELECTRA/LLM + 사람 검증 (최우선)
- ☐ AI 인간다움(X_2) 사람이 직접 코딩
- ☐ 3·4기 통제 실험 설계 (+ 매개효과는 SEM으로)

데이터·측정 신뢰성 노트

미션 기간: 공식 5일(05-03~05-07) + 팔로우업(~05-28), 분석은 미션Day 기준으로 늦은 제출까지 취합. 측정 강건성: 간이→정식 KNU 사전으로 바뀌도 결론 동일(순진한 효과조차 비유의 -0.074 , $p=.13$) → 결론이 측정 도구 때문에 나온 게 아니다.

재현 코드: analysis/full_pipeline.py · knu_reanalysis.py · mission_day_analysis.py | 원본 참가자 데이터는 저장소에 포함하지 않음.